TRABAJO PRÁCTICO N°1

Quarto

Quarto enables you to weave together content and executable code into a finished document. To learn more about Quarto see https://quarto.org.

Ejercicio 1:

Leo los datos

```
library(tidyverse)
```

```
── Attaching core tidyverse packages ──────────────────────── tidyverse 2.0.0 ──
✓ dplyr     1.2.1     ✓ readr     2.2.0
✓ forcats   1.0.1     ✓ stringr   1.6.0
✓ ggplot2   4.0.3     ✓ tibble    3.3.1
✓ lubridate 1.9.5     ✓ tidyr     1.3.2
✓ purrr     1.2.2
── Conflicts ────────────────────────────────────────── tidyverse_conflicts() ──
✖ dplyr::filter() masks stats::filter()
✖ dplyr::lag()    masks stats::lag()
ℹ Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
errors
```

```
datos <- read_csv2("elcuy.csv")
```

```
ℹ Using "','" as decimal and "'.'" as grouping mark. Use `read_delim()` for more control.
Rows: 117 Columns: 10── Column specification
────────────────────────────────────────────────────────
Delimiter: ";"
chr (2): Especie, Pastoreo
dbl (8): emergencia, densidad, Transecta, Año, mes, parche, hum_sup, hum_prof
ℹ Use `spec()` to retrieve the full column specification for this data.
ℹ Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

Veamos las columnas y las primeras filas

```
glimpse(datos)
```

```
Rows: 117
Columns: 10
$ Especie    <chr> "Senecio filaginoides", "Gilia sp", "Ranunculacea sp", "Pap…
$ emergencia <dbl> 1, 2, 2, 1, 1, 1, 5, 3, 1, 1, 1, 1, 1, 17, 18, 1, 3, 2, 6, …
$ densidad   <dbl> 1, 2, 2, 1, 1, 1, 5, 3, 1, 1, 1, 1, 1, 17, 18, 1, 3, 2, 6, …
$ Pastoreo   <chr> "Sin pastoreo", "Sin pastoreo", "Sin pastoreo", "Sin pastor…
$ Transecta  <dbl> 1, 1, 1, 1, 2, 2, 1, 1, 1, 1, 1, 2, 2, 2, 2, 2, 1, 1, 1, 1,…
$ Año        <dbl> 13, 13, 13, 13, 13, 13, 13, 13, 13, 13, 13, 13, 13, 13, 13,…
$ mes        <dbl> 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 11, 11, 11,…
```

```
$ parche     <dbl> 0, 1, 1, 1, 1, 1, 0, 1, 0, 1, 1, 0, 0, 1, 1, 1, 0, 0, 1, 1,…
$ hum_sup    <dbl> 11.67, 9.11, 9.11, 9.11, 9.47, 9.47, 16.55, 12.99, 16.55, 1…
$ hum_prof   <dbl> 11.17, 8.64, 8.64, 8.64, 9.29, 9.29, 8.28, 8.70, 8.28, 8.70…
```

```
head(datos)
```

```
# A tibble: 6 × 10
  Especie      emergencia densidad Pastoreo Transecta   Año   mes parche hum_sup
  <chr>             <dbl>    <dbl> <chr>        <dbl> <dbl> <dbl>  <dbl>   <dbl>
1 Senecio fil…          1        1 Sin pas…         1    13     9      0   11.7
2 Gilia sp              2        2 Sin pas…         1    13     9      1    9.11
3 Ranunculace…          2        2 Sin pas…         1    13     9      1    9.11
4 Pappostipa …          1        1 Sin pas…         1    13     9      1    9.11
5 Ranunculace…          1        1 Sin pas…         2    13     9      1    9.47
6 Gilia sp              1        1 Sin pas…         2    13     9      1    9.47
# ℹ 1 more variable: hum_prof <dbl>
```

Calculo las frecuencias:

```
datos %>%
  count(Especie, Pastoreo, emergencia)
```

```
# A tibble: 86 × 4
   Especie               Pastoreo     emergencia     n
   <chr>                 <chr>             <dbl> <int>
 1 Bromus catharticus    Pastoreo              1     1
 2 Bromus catharticus    Pastoreo              4     1
 3 Bromus catharticus    Pastoreo              9     1
 4 Bromus catharticus    Sin pastoreo          1     1
 5 Bromus catharticus    Sin pastoreo          2     1
 6 Bromus catharticus    Sin pastoreo          5     1
 7 Draba australis       Sin pastoreo          1     1
 8 Euphorbia colina      Pastoreo              1     1
 9 Gayophytum micranthum Pastoreo              1     1
10 Gayophytum micranthum Sin pastoreo          1     1
# ℹ 76 more rows
```

```
#Guardo la tabla:
frecuencias <- datos %>%
  count(Especie, Pastoreo, emergencia)
```

2) ordeno de mayor a menor según frecuencia de emergencia registrada

```
datos %>%
  count(Especie, Pastoreo, emergencia) %>%
  arrange(desc(n))
```

```
# A tibble: 86 × 4
   Especie              Pastoreo     emergencia     n
   <chr>                <chr>             <dbl> <int>
 1 Pappostipa sp        Pastoreo              1     5
 2 Ranunculacea sp      Sin pastoreo          2     4
```

```
 3 Hoffmannseggia sp    Sin pastoreo          1     3
 4 Gilia sp             Pastoreo              2     2
 5 Gilia sp             Pastoreo              8     2
 6 Gilia sp             Pastoreo             17     2
 7 Gilia sp             Sin pastoreo          1     2
 8 Gilia sp             Sin pastoreo          3     2
 9 Gilia sp             Sin pastoreo          7     2
10 Grindelia chiloensis Sin pastoreo          1     2
# ℹ 76 more rows
```

3) Agregar fecha a la tabla de frecuencia

```
datos_fecha <- datos %>%
  mutate(
    fecha = as.Date(
      paste0(2000 + Año, "-", mes, "-01")
    )
  )

datos_fecha %>%
  count(Especie, Pastoreo, fecha)
```

```
# A tibble: 63 × 4
   Especie               Pastoreo     fecha          n
   <chr>                 <chr>        <date>     <int>
 1 Bromus catharticus    Pastoreo     2014-06-01     2
 2 Bromus catharticus    Pastoreo     2014-09-01     1
 3 Bromus catharticus    Sin pastoreo 2014-06-01     1
 4 Bromus catharticus    Sin pastoreo 2014-09-01     2
 5 Draba australis       Sin pastoreo 2014-09-01     1
 6 Euphorbia colina      Pastoreo     2013-09-01     1
 7 Gayophytum micranthum Pastoreo     2014-09-01     1
 8 Gayophytum micranthum Sin pastoreo 2014-09-01     1
 9 Gilia sp              Pastoreo     2013-09-01     1
10 Gilia sp              Pastoreo     2013-11-01     2
# ℹ 53 more rows
```

4) Crear otra variable: logaritmo de emergencia para reducir el sesgo

```
datos <- datos %>%
  mutate(log_emergencia = log(emergencia))
```

5) Calcular la media, desviación estándar, coeficiente de variación de la emergencia por especie de acuerdo con el momento del año.

```
datos %>%
  group_by(Especie, mes) %>%
  summarise(
    media = mean(emergencia, na.rm = TRUE),
    desvio_estandar = sd(emergencia, na.rm = TRUE),
    coef_variacion = (desvio_estandar / media) * 100
  )
```

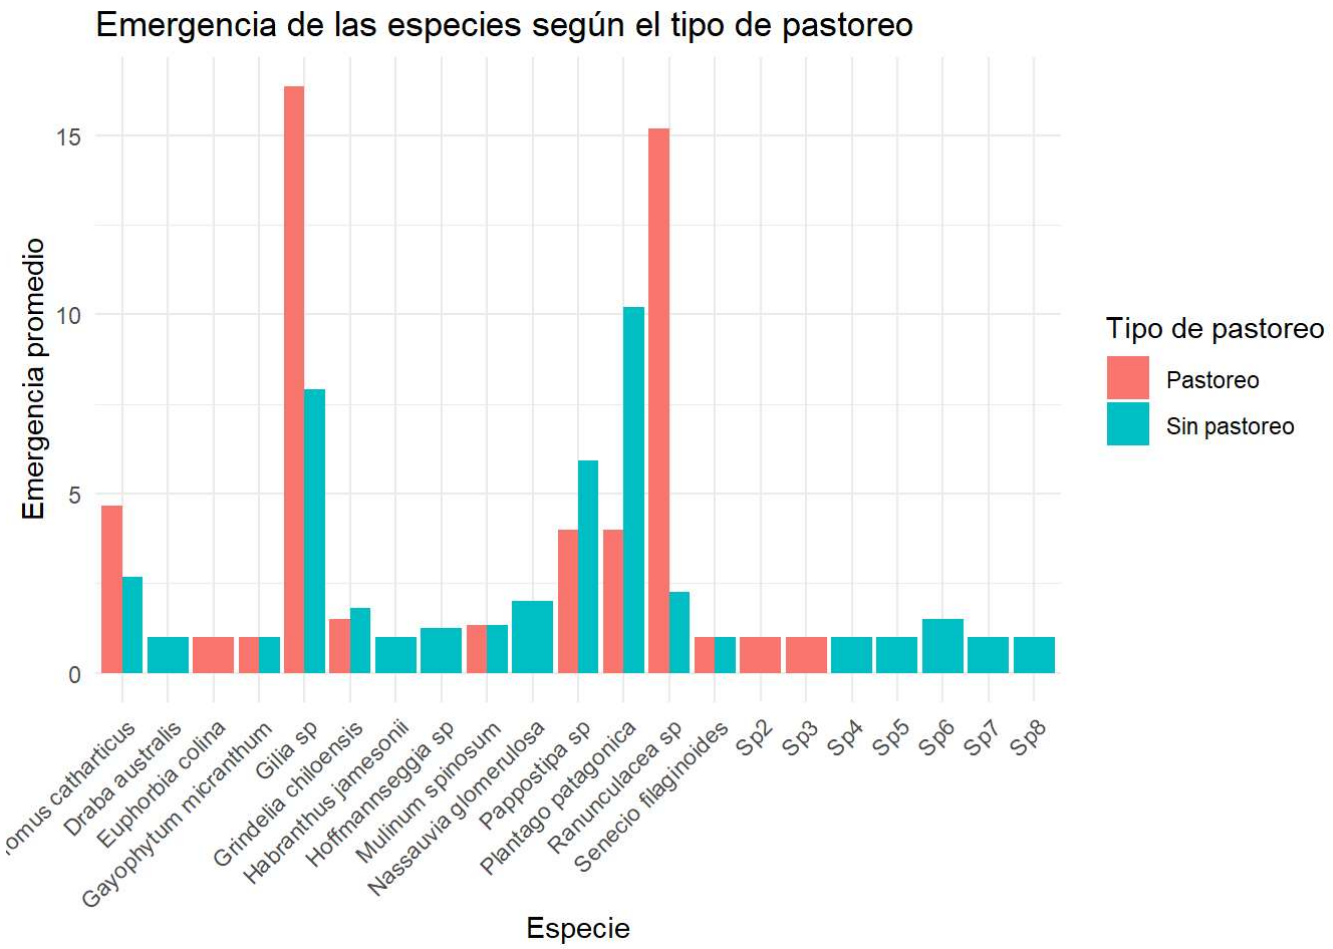
```
`summarise()` has regrouped the output.
ℹ Summaries were computed grouped by Especie and mes.
ℹ Output is grouped by Especie.
ℹ Use `summarise(.groups = "drop_last")` to silence this message.
ℹ Use `summarise(.by = c(Especie, mes))` for per-operation grouping
  (`?dplyr::dplyr_by`) instead.

# A tibble: 37 × 5
# Groups:   Especie [21]
   Especie                 mes media desvio_estandar coef_variacion
   <chr>                 <dbl> <dbl>           <dbl>          <dbl>
 1 Bromus catharticus        6  6               2.65           44.1
 2 Bromus catharticus        9  1.33            0.577          43.3
 3 Draba australis           9  1              NA              NA
 4 Euphorbia colina          9  1              NA              NA
 5 Gayophytum micranthum     9  1               0               0
 6 Gilia sp                  6 22.5            29.7           132.
 7 Gilia sp                  9  7.27            5.87           80.7
 8 Gilia sp                 11  2.33            1.53           65.5
 9 Grindelia chiloensis      6  2.5             0.707          28.3
10 Grindelia chiloensis      9  1.33            0.577          43.3
# ℹ 27 more rows
```

6) Realice un gráfico que permita visualizar la emergencia de cada especie. A partir de la observación, ¿considera que existen diferencias según el tipo de pastoreo?

¿brotan más o menos con pastoreo o no?

```r
datos %>%
  group_by(Especie, Pastoreo) %>%
  summarise(
    emergencia_media = mean(emergencia, na.rm = TRUE),
    .groups = "drop"
  ) %>%
  ggplot(aes(x = Especie, y = emergencia_media, fill = Pastoreo)) +
  geom_col(position = "dodge") +
  labs(
    title = "Emergencia de las especies según el tipo de pastoreo",
    x = "Especie",
    y = "Emergencia promedio",
    fill = "Tipo de pastoreo"
  ) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



Conclusión: *Podemos visualizar que las especies que más brote poseen son Gilia sp y Ran un culacea sp con y sin pastoreo. Sin embargo, ambas crecen más con pastoreo que sin pastoreo.*

7. En la base de datos hay especies no identificadas, hay que escribirlas como no identificadas y filtrarlas.

```
library(stringr)

datos <- datos %>%
  mutate(
    Especie = if_else(
      str_detect(Especie, "^Sp[0-9]+$"),
      "No identificadas",
      Especie
    )
  )


datos_filtrados <- datos %>%
  filter(Especie != "No identificadas")
```

8) Realizar un gráfico **de las especies más frecuentes** que muestre los valores medios de emergencia por mes, año y tipo de pastoreo. ¿Concuerda el patrón observado con la descripción teorica del enunciado?

```
#primero vamos a encontrar las especies más frecuentes.
datos_filtrados %>%
```

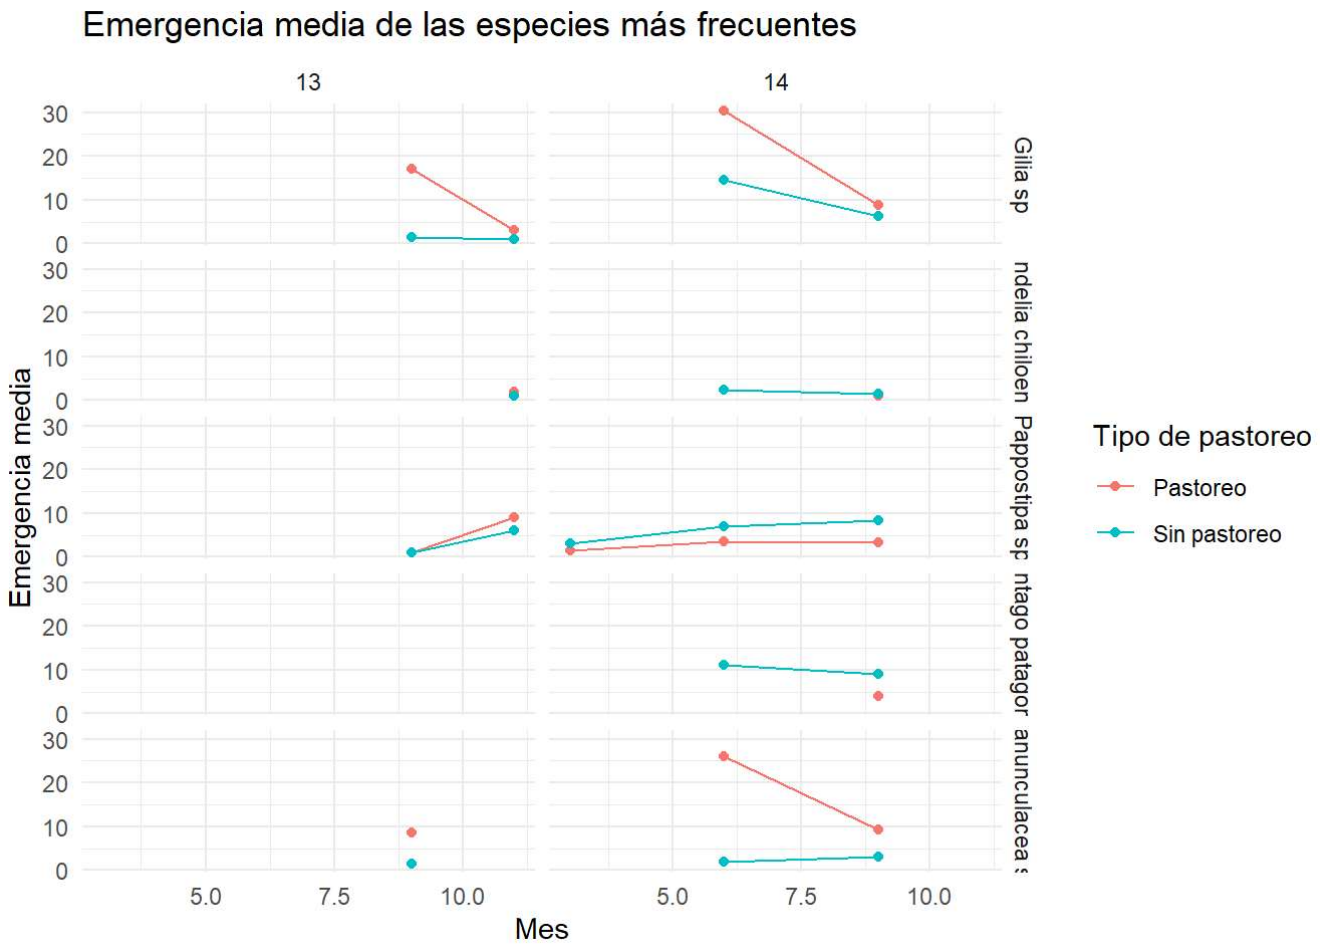
```
  count(Especie, sort = TRUE)
```

```
# A tibble: 14 × 2
   Especie                   n
   <chr>                 <int>
 1 Pappostipa sp            26
 2 Gilia sp                 22
 3 Ranunculacea sp          19
 4 Grindelia chiloensis      7
 5 Plantago patagonica       7
 6 Bromus catharticus        6
 7 Mulinum spinosum          6
 8 Hoffmannseggia sp         4
 9 Senecio filaginoides      4
10 Gayophytum micranthum     2
11 Habranthus jamesonii      2
12 Nassauvia glomerulosa     2
13 Draba australis           1
14 Euphorbia colina          1
```

```
#las 5 especies más frecuentes:
especies_frecuentes <- datos_filtrados %>%
  count(Especie, sort = TRUE) %>%
  slice_head(n = 5)

#media emergente
datos_filtrados %>%
  semi_join(especies_frecuentes, by = "Especie") %>%
  group_by(Especie, mes, Año, Pastoreo) %>%
  summarise(
    emergencia_media = mean(emergencia, na.rm = TRUE),
    .groups = "drop"
  ) %>%
  ggplot(aes(x = mes, y = emergencia_media,
             color = Pastoreo, group = Pastoreo)) +
  geom_line() +
  geom_point() +
  facet_grid(Especie ~ Año) +
  labs(
    title = "Emergencia media de las especies más frecuentes",
    x = "Mes",
    y = "Emergencia media",
    color = "Tipo de pastoreo"
  ) +
  theme_minimal()
```

```
`geom_line()`: Each group consists of only one observation.
ℹ Do you need to adjust the group aesthetic?
`geom_line()`: Each group consists of only one observation.
ℹ Do you need to adjust the group aesthetic?
```



Cómo leer el gráfico?

- **Eje X:** mes.
- **Eje Y:** emergencia media.
- **Líneas:** tipo de pastoreo.
- **Filas:** especies.
- **Columnas:** año.

Así podés observar si la emergencia cambia a lo largo del año y si el comportamiento es diferente entre **pastoreo** y **sin pastoreo**.

Interpretación del gráfico

Se observa que **la emergencia varía según la especie, el año, el mes y el tipo de pastoreo**.

En varias especies se observa una diferencia entre los tratamientos. Por ejemplo:

- **Gilia sp:** presenta una emergencia claramente mayor con **pastoreo** que sin pastoreo, especialmente en 2013 y 2014.
- **Ranunculacea:** también muestra valores mayores con **pastoreo**, particularmente al comienzo del período observado.

- **Pappostipa:** las diferencias entre tratamientos son menores y el comportamiento cambia según el año.
- **delachile:** presenta valores relativamente bajos y diferencias pequeñas entre los tratamientos.

Además, en varias especies se observa una **disminución de la emergencia hacia los meses posteriores**, aunque el comportamiento no es igual para todas las especies.

EJERCICIO N° 2) Encuesta para estudiar los habitos alimenticios y el consumo de alcohol en estudiantes de nivel secundario.

1) Importamos el archivo y seleccionamos las columnas 8 a 11 y 47 a 51.

```
#leo los datos
datos <- read_csv2("encuesta.csv")
```

```
ℹ Using "','" as decimal and "'.'" as grouping mark. Use `read_delim()` for more control.

New names:
Rows: 559 Columns: 59
── Column specification
──────────────────────────────────────────────────────── Delimiter: ";" chr
(47): fecha_carga, Nombre_encuestador, Fecha_encuesta, Datos_muestra, E... dbl
(5): Año, Curso, Edad, como_te_sentis_con_tu_pes, como_te_sentis_en_fu... time
(7): Hora...14, Hora...17, Hora...20, Hora...23, Hora...26, Hora...29,...
ℹ Use `spec()` to retrieve the full column specification for this data. ℹ
Specify the column types or set `show_col_types = FALSE` to quiet this message.
• `Hora` -> `Hora...14`
• `Comida` -> `Comida...15`
• `Bebida` -> `Bebida...16`
• `Hora` -> `Hora...17`
• `Comida` -> `Comida...18`
• `Bebida` -> `Bebida...19`
• `Hora` -> `Hora...20`
• `Comida` -> `Comida...21`
• `Bebida` -> `Bebida...22`
• `Hora` -> `Hora...23`
• `Comida` -> `Comida...24`
• `Bebida` -> `Bebida...25`
• `Hora` -> `Hora...26`
• `Comida` -> `Comida...27`
• `Bebida` -> `Bebida...28`
• `Hora` -> `Hora...29`
• `Comida` -> `Comida...30`
• `Bebida` -> `Bebida...31`
• `Hora` -> `Hora...32`
• `Comida` -> `Comida...33`
• `Bebida` -> `Bebida...34`
```

```
#selecciono las columnas 8 a 11 y 47 a 51.
datos_seleccionados <- datos %>%
  select(8:11, 47:51)
```

```r
#convertirlo a dataframe
datos_df <- as.data.frame(datos_seleccionados)
```

Las diferencias que veo en una y otra tabla es que:

- Tibble: muestra los datos de forma ordenada y resumida. No muestra todos los datos. También, aparecen los tipos de datos en las columnas, debajo de los nombres (si es caracter, o numeric, etc.)
- Data.frame: muestra los datos de una forma más extensa y no muestra los tipos de datos.

2) Filtrar a los estudiantes que responden SI a ¿consumis alcohol?

Calcular el % que representan sobre el total. Luego, desagregar por sexo y contabilizar las frec. absolutas y relativas.

```r
#total de estudiantes
total<-nrow(datos)

#filtrar quienes responden afirmativamente
alcohol_si<-datos%>%
  filter(consumiste_alcohol == "Sí")

#Calcular el %
porcentaje<-nrow(alcohol_si)/total*100
porcentaje
```

```
[1] 89.26655
```

```r
#desagregar por sexo para obtener la frec. absoluta
alcohol_si %>%
  count(Sexo)
```

```
# A tibble: 3 × 2
  Sexo          n
  <chr>     <int>
1 Femenino    237
2 Masculino   260
3 <NA>          2
```

```r
#frecuencia relativa
alcohol_si %>%
  count(Sexo) %>%
  mutate(porcentaje=n/sum(n)*100)
```

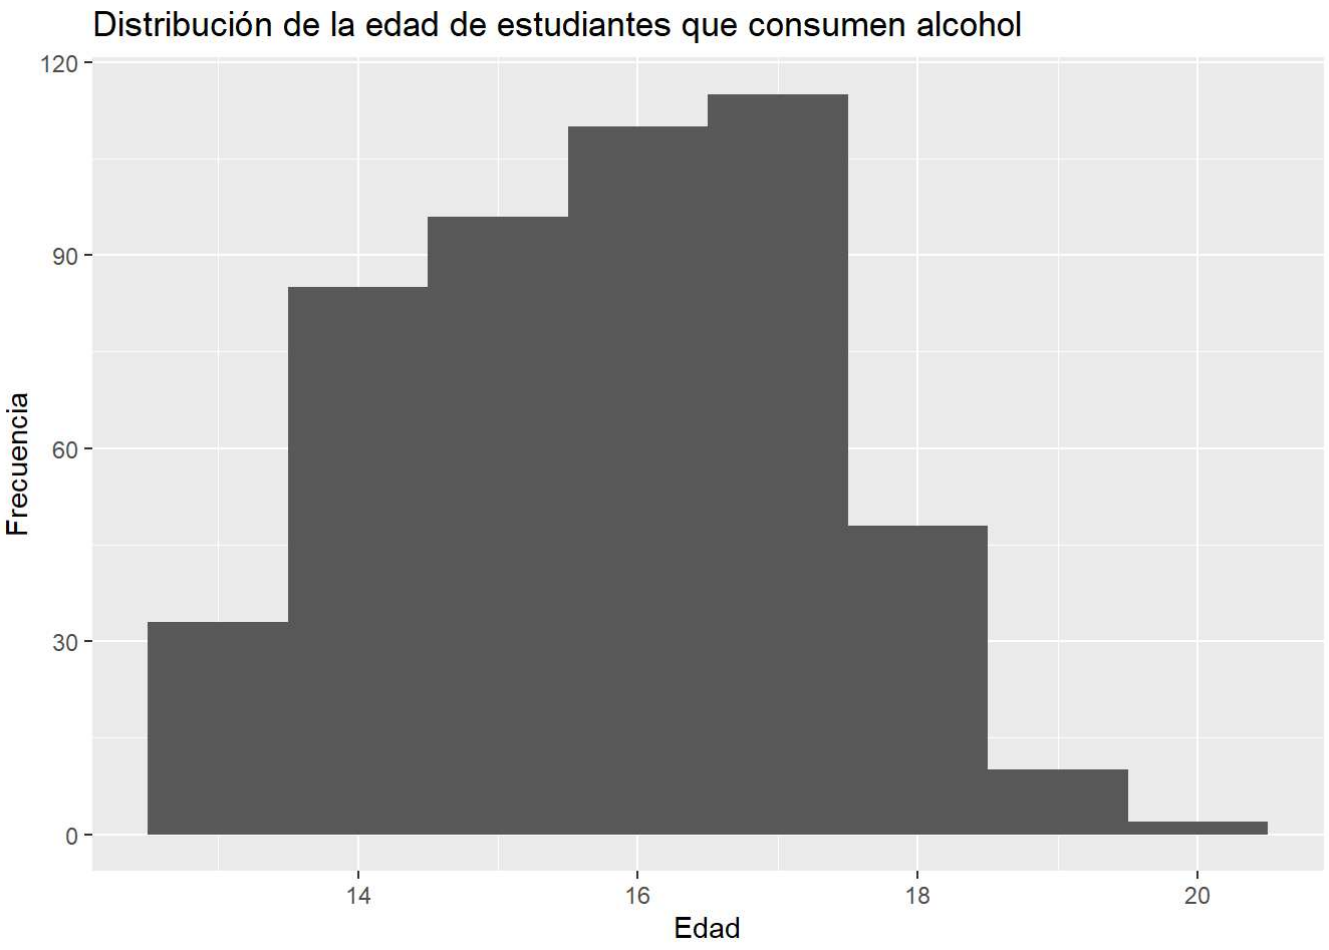
```
# A tibble: 3 × 3
  Sexo          n porcentaje
  <chr>     <int>      <dbl>
1 Femenino    237     47.5
2 Masculino   260     52.1
3 <NA>          2      0.401
```

Respuesta: Se visualiza que hay 260 hombres que contestaron que si, mientras que 237 mujeres contestaron que si.

3) Para aquellos que respondieron que si, crear un histograma de la variable edad y compárelo segregando por sexo.

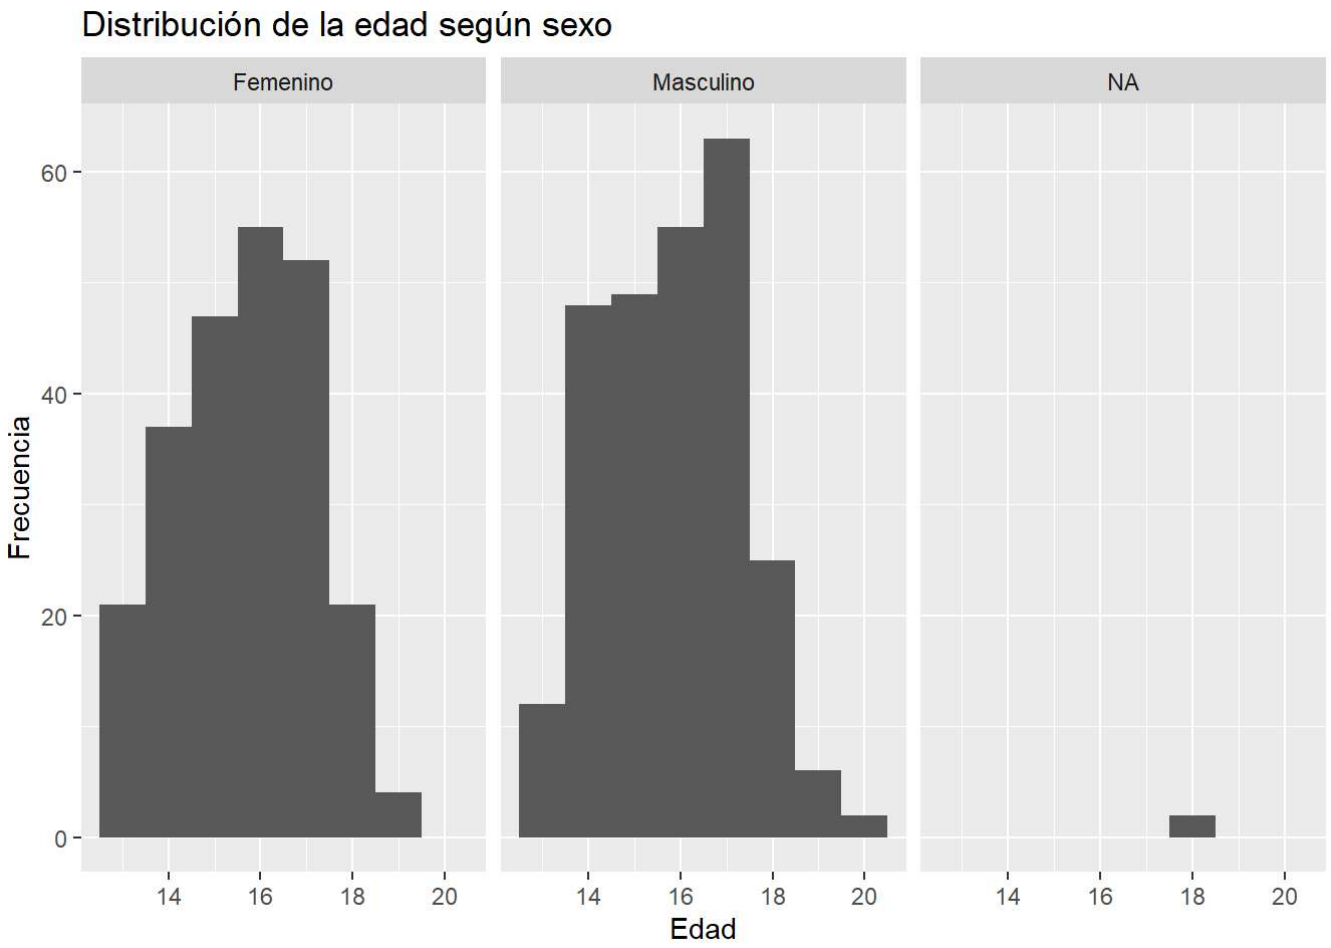
```
#filtrar quienes responden afirmativamente
alcohol_si<-datos%>%
  filter(consumiste_alcohol == "Sí")

#histograma
ggplot(alcohol_si, aes(x=Edad))+
  geom_histogram(binwidth=1)+
  labs(
    title= "Distribución de la edad de estudiantes que consumen alcohol",
    x="Edad",
    y ="Frecuencia"
  )
```




```
#comparar por sexo
ggplot(alcohol_si, aes(x = Edad)) +
  geom_histogram(binwidth = 1) +
  facet_wrap(~Sexo) +
  labs(
    title = "Distribución de la edad según sexo",
    x = "Edad",
```

```
    y = "Frecuencia"
  )
```



En el gráfico de frecuencia vs Edad, podemos ver que los que más consumen alcohol son entre 16 y 18 años.

En el gráfico que diferencia femenino y masculino, podemos visualizar que presentan una distribución similar, concentrándose principalmente entre los 14 y 18. En ambos, las mayores frecuencias se encuentran entre los 15 y 17 años. Sin embargo, el hombre tiene mayor concentración en todas las edades con respecto a la mujer, pero además, tiene una mayor concentración entre 16 y 17 años, mientras que la mujer se concentra más entre los 15 y 16 años. Otra diferencia, es que los hombre presentan algunos casos en edades mayores, llegando hasta los 20 años, mientras que las mujeres hay pocos casos de 19 años.

4) Calcular los % de respuesta afirmativa “Tuviste un exceso de alcohol?”.

i- Crear una nueva columna mediante un condicional de tidyverse que clasifica a los estudiantes en básico (1°,2° y 3°) y superior (4°, 5° y 6°).

```
#Sacamos el % de las personas que han tenido exceso
datos %>%
  summarise(
    porcentaje = mean(tuviste_un_exceso_de_alcohol == "Sí", na.rm = TRUE) * 100
  )
```

```
# A tibble: 1 × 1
  porcentaje
       <dbl>
1       42.4
```

```
#Creamos la variable Básico y Superior
datos <- datos %>%
  mutate(
    nivel = case_when(
      Curso %in% c(1, 2, 3) ~ "Básico",
      Curso %in% c(4, 5, 6) ~ "Superior",
      TRUE ~ NA_character_
    )
  )
```

ii- Calcular el % de estudiantes con respuesta afirmativa según sexo y nivel educativo

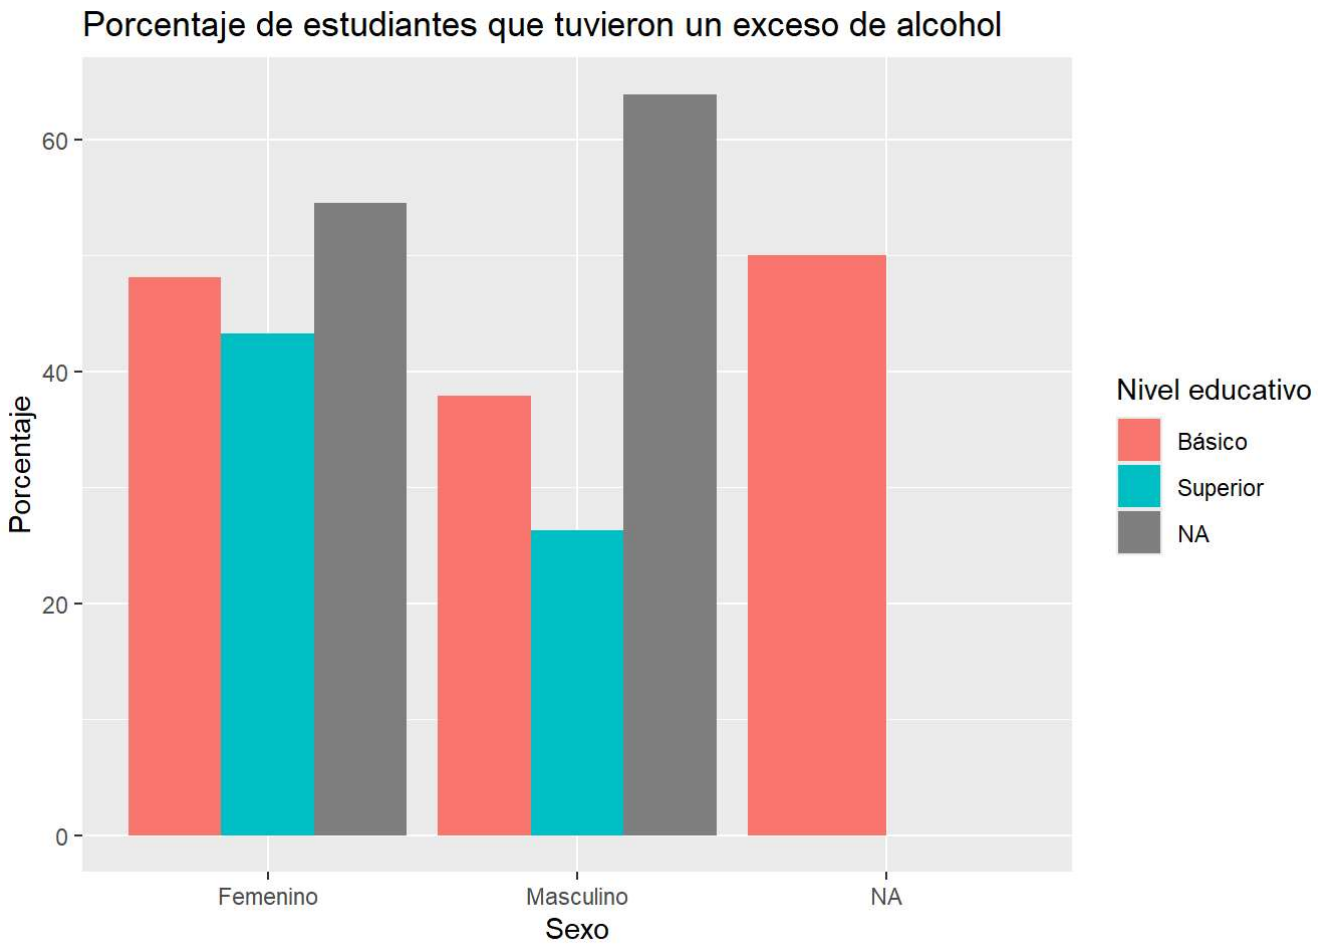
```
resultados <- datos %>%
  group_by(Sexo, nivel) %>%
  summarise(
    porcentaje = mean(tuviste_un_exceso_de_alcohol == "Sí", na.rm = TRUE) * 100,
    .groups = "drop"
  )

resultados
```

```
# A tibble: 8 × 3
  Sexo      nivel    porcentaje
  <chr>     <chr>         <dbl>
1 Femenino  Básico         48.1
2 Femenino  Superior       43.3
3 Femenino  <NA>           54.5
4 Masculino Básico         37.9
5 Masculino Superior       26.2
6 Masculino <NA>           63.9
7 <NA>      Básico         50
8 <NA>      Superior        0
```

iii- Elaborar un gráfico de barras para representar los resultdos obtenidos.

```
ggplot(resultados, aes(x = Sexo, y = porcentaje, fill = nivel)) +
  geom_col(position = "dodge") +
  labs(
    title = "Porcentaje de estudiantes que tuvieron un exceso de alcohol",
    x = "Sexo",
    y = "Porcentaje",
    fill = "Nivel educativo"
  )
```



vemos que hay más % de mujeres que han tenido un exceso de alcohol que hombres.

5) Para las restantes variables de consumo, calcular la cantidad de respuestas afirmativas segregandas por sexo.

```
#Cantidad de respuestas afirmativas por sexo
table(datos$Sexo, datos$`consumiste_alcohol_este_anio`)
```

```
           No No contesta  Sí
 Femenino   27           1 230
 Masculino  53           1 244
```

```
table(datos$Sexo, datos$`consumiste_alcohol_este_mes`)
```

```
           No No contesta  Sí
 Femenino   68           2 188
 Masculino  88           2 208
```

```
table(datos$Sexo, datos$`consumiste_alcohol_esta_semana`)
```

```
           No No contesta  Sí
 Femenino  113           2 143
 Masculino 145           2 151
```

```
table(datos$Sexo, datos$`tuviste_un_exceso_de_alcohol`)
```

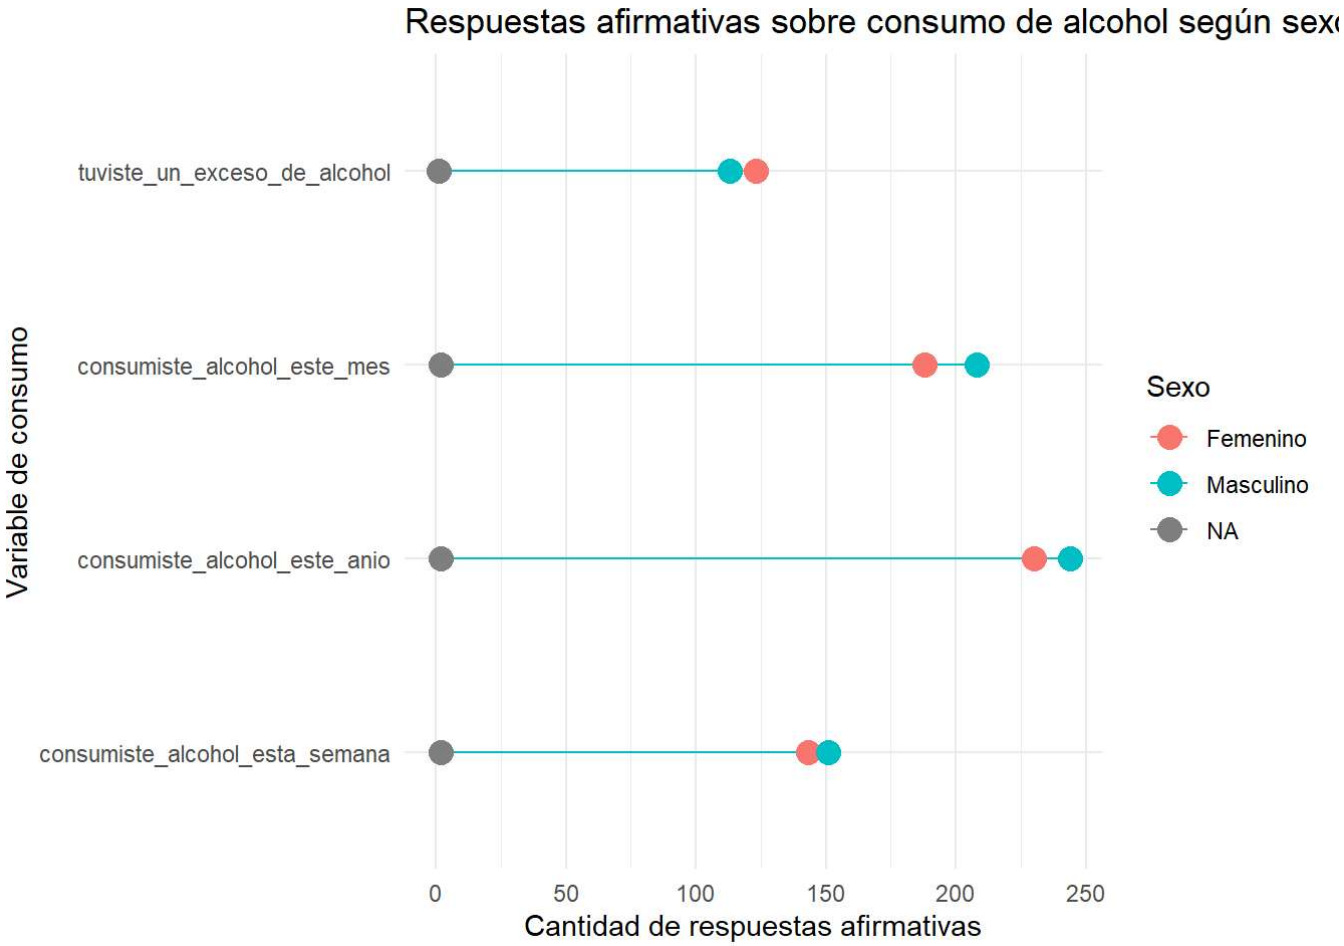
```
            No No contesta  Sí
  Femenino  129           6 123
  Masculino 180           5 113
```

6)

```
library(dplyr)
library(tidyr)
library(ggplot2)

datos_lollipop <- datos %>%
  pivot_longer(
    cols = c(
      `consumiste_alcohol_este_anio`,
      `consumiste_alcohol_este_mes`,
      `consumiste_alcohol_esta_semana`,
      `tuviste_un_exceso_de_alcohol`
    ),
    names_to = "Consumo",
    values_to = "Respuesta"
  ) %>%
  filter(Respuesta == "Sí") %>%
  count(Consumo, Sexo)

#gráfico
ggplot(datos_lollipop, aes(x = n, y = Consumo, color = Sexo)) +
  geom_segment(
    aes(x = 0, xend = n, y = Consumo, yend = Consumo)
  ) +
  geom_point(size = 4) +
  labs(
    title = "Respuestas afirmativas sobre consumo de alcohol según sexo",
    x = "Cantidad de respuestas afirmativas",
    y = "Variable de consumo",
    color = "Sexo"
  ) +
  theme_minimal()
```



conclusión: los puntos de cada variable, corresponden a los dos sexos. Se visualiza claramente, que en cada uno de los consumos, hay más % de masculinos que de femeninos, salvo en exceso de alcohol.

EJERCICIO 5)

Utilizando, ahora, los datos de telefonía movil para el analisis economico del ingreso por medio por usuario (Average Revenue Per User, ARPU), considere las siguientes variables: